



电子科技大学

University of Electronic Science and Technology of China

《机器学习》

第八章：集成学习



任亚洲

yazhou.ren@uestc.edu.cn

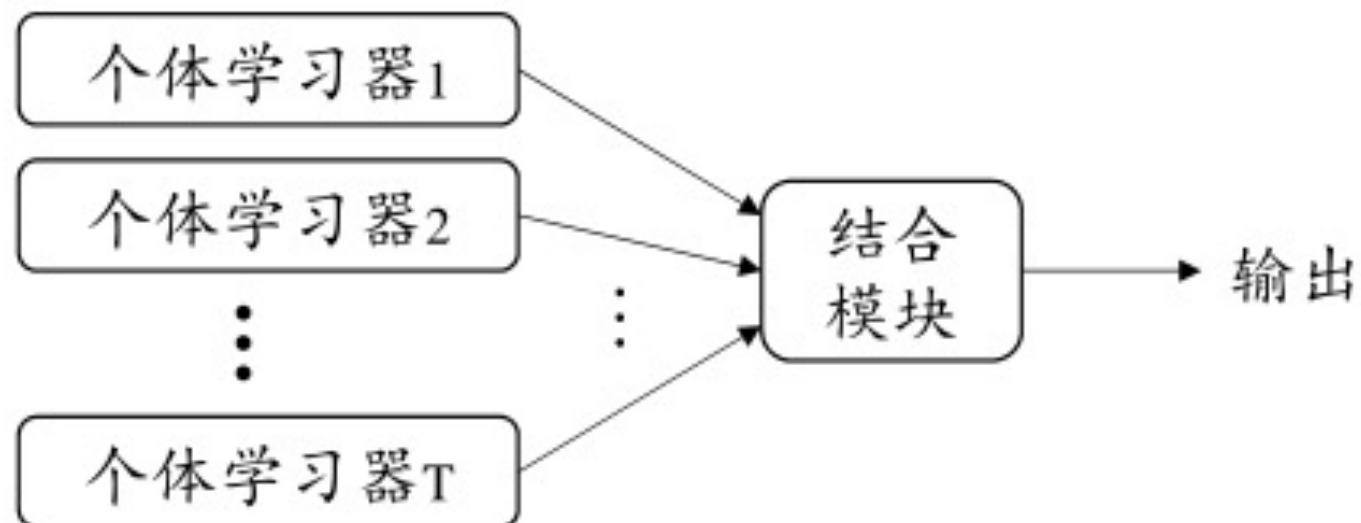
计算机科学与工程学院

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

个体与集成

- 集成学习(ensemble learning)通过构建并结合多个学习器来提升性能



课堂讨论

- 集成学习中，个体学习器应如何选择？

个体与集成

- 考虑一个简单的例子，在二分类问题中，假定3个分类器在三个样本中的表现如下图所示，其中√ 表示分类正确，X 号表示分类错误，集成的结果通过投票产生。

	测试例1	测试例2	测试例3		测试例1	测试例2	测试例3		测试例1	测试例2	测试例3
h_1	√	√	×	h_1	√	√	×	h_1	√	×	×
h_2	×	√	√	h_2	√	√	×	h_2	×	√	×
h_3	√	×	√	h_3	√	√	×	h_3	×	×	√
集群	√	√	√	集群	√	√	×	集群	×	×	×
(a) 集群提升性能				(b) 集群不起作用				(c) 集群起负作用			

□ 集成个体应：好而不同

个体与集成 – 简单分析

- 考虑二分类问题，假设基分类器的错误率为：

$$P(h_i(\mathbf{x}) \neq f(\mathbf{x})) = \epsilon$$

- 假设集成通过简单投票法结合 T 个分类器，若有超过半数的基分类器正确则分类就正确

$$H(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^T h_i(\mathbf{x}) \right)$$

个体与集成 – 简单分析

- 假设基分类器的错误率相互独立，则由Hoeffding霍夫丁不等式可得集成的错误率为：

$$\begin{aligned} P(H(\mathbf{x}) \neq f(\mathbf{x})) &= \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1-\epsilon)^k \epsilon^{T-k} \\ &\leq \exp\left(-\frac{1}{2}T(1-2\epsilon)^2\right) \end{aligned}$$

- 上式显示，在一定条件下，随着集成分类器数目的增加，集成的错误率将指数级下降，最终趋向于0

个体与集成 – 简单分析


- 上面的分析有一个关键假设：基学习器的误差相互独立
- 现实任务中，个体学习器是为解决同一个问题训练出来的，显然**不可能互相独立**
- 事实上，个体学习器的“**准确性**”和“**多样性**”本身就存在冲突
- 如何产生“好而不同”的个体学习器是集成学习研究的**核心**
- 集成学习大致可分为两大类
 - Boosting: 串行，个体（基）学习器**存在强依赖关系**
 - Bagging和随机森林：个体（基）学习器**不存在强依赖关系**

集成学习

- 个体与集成
- Boosting
 - **Adaboost**
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

Boosting

- 个体学习器存在强依赖关系，
- 串行生成
- 每次调整训练数据的样本分布



Boosting - Boosting算法

Input: Sample distribution \mathcal{D} ;
Base learning algorithm \mathcal{L} ;
Number of learning rounds T .

Process:

1. $\mathcal{D}_1 = \mathcal{D}$. % Initialize distribution
2. **for** $t = 1, \dots, T$:
3. $h_t = \mathcal{L}(\mathcal{D}_t)$; % Train a weak learner from distribution \mathcal{D}_t
4. $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$; % Evaluate the error of h_t
5. $\mathcal{D}_{t+1} = \text{Adjust_Distribution}(\mathcal{D}_t, \epsilon_t)$
6. **end**

Output: $H(\mathbf{x}) = \text{Combine_Outputs}(\{h_1(\mathbf{x}), \dots, h_t(\mathbf{x})\})$

Boosting – AdaBoost算法

□ Boosting族算法最著名的代表是AdaBoost

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 \mathcal{L} ;
训练轮数 T .

过程:


- 1: $\mathcal{D}_1(\mathbf{x}) = 1/m$.
- 2: **for** $t = 1, 2, \dots, T$ **do**
- 3: $h_t = \mathcal{L}(D, \mathcal{D}_t)$;
- 4: $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$;
- 5: **if** $\epsilon_t > 0.5$ **then break**
- 6: $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$;
- 7:
$$\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$$
$$= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$$
- 8: **end for**

输出: $H(\mathbf{x}) = \text{sign} \left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

Boosting – AdaBoost注意事项

- 数据分布的学习
 - 重赋权法
 - 重采样法
- 利用“重采样法”实现重新启动，避免训练过程过早停止

Boosting Example




Each data point has
a class label:

$$y_t = \begin{cases} +1 & (\text{red circle}) \\ -1 & (\text{cyan circle}) \end{cases}$$

and a weight:

$$w_t = 1$$

Boosting Example



Each data point has
a class label:


$$y_t = \begin{cases} +1 & (\text{red circle}) \\ -1 & (\text{cyan circle}) \end{cases}$$

and a weight:

$$w_t = 1$$

$h \Rightarrow p(\text{error}) = 0.5$ it is at chance

Boosting Example



Each data point has
a class label:

$$y_t = \begin{cases} +1 & (\text{red circle}) \\ -1 & (\text{cyan circle}) \end{cases}$$


and a weight:

$$w_t = 1$$

This one seems to be the best

This is a '**weak classifier**': It performs slightly better than chance.

Boosting Example



Each data point has
a class label:


$$y_t = \begin{cases} +1 & (\text{red}) \\ -1 & (\text{teal}) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again

Boosting Example



Each data point has
a class label:


$$y_t = \begin{cases} +1 & (\text{red}) \\ -1 & (\text{cyan}) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again

Boosting Example



Each data point has
a class label:


$$y_t = \begin{cases} +1 & (\text{red}) \\ -1 & (\text{cyan}) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again

Boosting Example



Each data point has
a class label:


$$y_t = \begin{cases} +1 & (\text{red}) \\ -1 & (\text{cyan}) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again


Boosting Example




The strong (non- linear) classifier is built as the combination of all the weak (linear) classifiers.

Boosting – AdaBoost实验


基分类器：决策树桩（单层决策树）



(a) 3个基学习器



(b) 5个基学习器



(c) 11个基学习器

- 从偏差-方差的角度：**降低偏差**，可对泛化性能相当弱的学习器构造出很强的集成 [偏差/方差：参考西瓜书2.5]

集成学习

- 个体与集成
- Boosting
 - Adaboost
- **Bagging**与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

Bagging与随机森林

- 个体学习器不存在强依赖关系
- 并行化生成
- 自助采样法

Bagging与随机森林 – Bagging算法

输入：训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 \mathcal{L} ;
训练轮数 T .

过程：

```
1: for  $t = 1, 2, \dots, T$  do  
2:    $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$   
3: end for
```

输出： $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y)$

对于一个样本，它在某一次含 m 个样本的训练集的随机采样中，每次被采集到的概率是 $1/m$ ，不被采集到的概率为 $(1 - \frac{1}{m})$ ，如果 m 次采样都没有被采集中的概率是 $(1 - \frac{1}{m})^m$ ，当 $m \rightarrow \infty$ ， $(1 - \frac{1}{m})^m \rightarrow \frac{1}{e} \cong 0.368$

- 回归：取 T 个结果的均值

Bagging与随机森林 – Bagging算法特点

- **时间复杂度低**
 - 假定基学习器的计算复杂度为 $O(m)$ ，采样与投票/平均过程的复杂度为 $O(s)$ ，则bagging的复杂度大致为 $T(O(m)+O(s))$
 - 由于 $O(s)$ 很小且 T 是一个不大的常数
 - 因此训练一个bagging集成与直接使用基学习器的复杂度同阶
- **可使用包外估计**

Bagging与随机森林 – 包外估计

- $H^{oob}(x)$ 表示对样本 x 的包外预测，即仅考虑那些未使用样本 x 训练的基学习器在 x 上的预测

$$H^{oob}(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\mathbf{x}) = y) \cdot \mathbb{I}(\mathbf{x} \notin D_t)$$

□ Bagging泛化误差的包外估计为：

$$\epsilon^{oob} = \frac{1}{|D|} \sum_{(\mathbf{x}, y) \in D} \mathbb{I}(H^{oob}(\mathbf{x}) \neq y)$$

Bagging与随机森林- Bagging实验

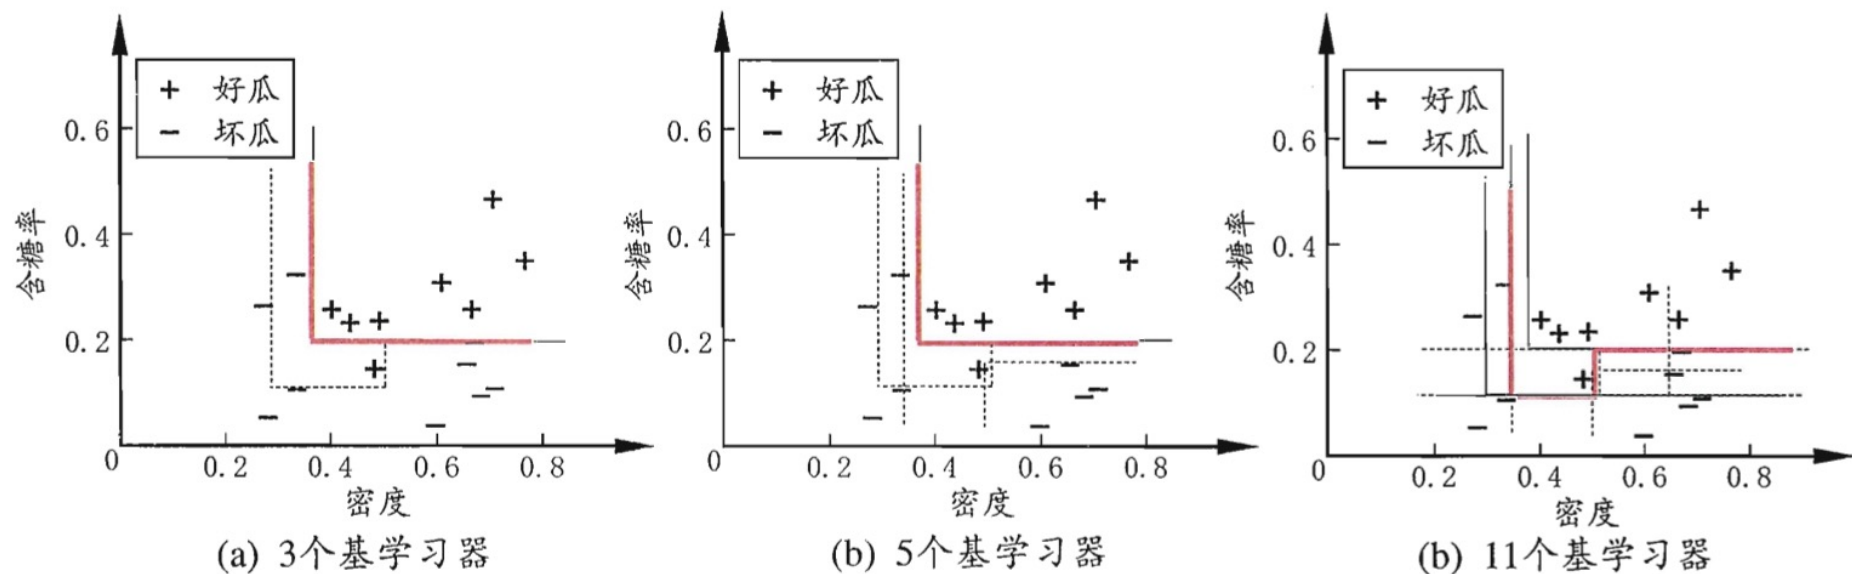


图 8.6 西瓜数据集 3.0α 上 Bagging 集成规模为 3、5、11 时, 集成(红色)与基学习器(黑色)的分类边界.

□ 从偏差-方差的角度：**降低方差**，在不剪枝的决策树、神经网络等易受样本影响的学习器上效果更好

Bagging与随机森林-随机森林

- 随机森林(Random Forest , 简称RF)是bagging的一个扩展变种
 - 被誉为 “代表集成学习技术水平的方法”
- 采样的随机性：
 - 与bagging一致
- 特征选择的随机性：
 - 随机选择一个特征子集，并从中计算最优分裂特征

Bagging与随机森林 – 随机森林算法

□ 随机森林算法


Input: Data set $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
Feature subset size K .

Process:


1. $N \leftarrow$ create a tree node based on D ;
2. **if** *all instances in the same class* **then return** N
3. $\mathcal{F} \leftarrow$ the set of features that can be split further;
4. **if** \mathcal{F} *is empty* **then return** N
5. $\tilde{\mathcal{F}} \leftarrow$ select K features from \mathcal{F} randomly;
6. $N.f \leftarrow$ the feature which has the best split point in $\tilde{\mathcal{F}}$;
7. $N.p \leftarrow$ the best split point on $N.f$;
8. $D_l \leftarrow$ subset of D with values on $N.f$ smaller than $N.p$;
9. $D_r \leftarrow$ subset of D with values on $N.f$ no smaller than $N.p$;
10. $N_l \leftarrow$ call the process with parameters (D_l, K) ;
11. $N_r \leftarrow$ call the process with parameters (D_r, K) ;
12. **return** N

Output: A random decision tree

Bagging与随机森林 – 随机森林实验



(a) glass 数据集




(b) auto-mpg 数据集

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

结合策略

- 学习器的组合可以从三个方面带来好处



- **统计的原因**：多个假设在训练集上达到同等性能，若使用单个，因为误选，导致泛化性能不佳；结合多个学习器会降低这个风险
- **计算的原因**：学习算法往往会陷入局部极小，有的局部极小点对应的泛化性能可能很糟，经过多次运行之后进行结合，可降低陷入糟糕的局部极小点的概率
- **表示的原因**：假设空间变大，有可能学到更好的近似

结合策略 – 平均法

- 简单平均法

$$H(\mathbf{x}) = \frac{1}{T} \sum_{i=1}^T h_i(\mathbf{x}).$$

- 加权平均法

$$H(\mathbf{x}) = \sum_{i=1}^T w_i h_i(\mathbf{x}) \quad w_i \geq 0 \quad \text{and} \quad \sum_{i=1}^T w_i = 1.$$

结合策略 – 平均法

- 简单平均法是加权平均法的特例
- 加权平均法在二十世纪五十年代被广泛使用
- 集成学习中的各种结合方法都可以看成是加权平均法的变种或特例
- 加权平均法可认为是集成学习研究的基本出发点
- 加权平均法未必一定优于简单平均法
 - 个体性能差距大
 - 个体性能差距小

结合策略 – 投票法

- 绝对多数投票法 (majority voting)

$$H(\mathbf{x}) = \begin{cases} c_j & \text{if } \sum_{i=1}^T h_i^j(\mathbf{x}) > \frac{1}{2} \sum_{k=1}^l \sum_{i=1}^T h_i^k(\mathbf{x}) \\ \text{rejection} & \text{otherwise.} \end{cases}$$

- 相对多数投票法 (plurality voting)

$$H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T h_i^j(\mathbf{x})}$$

- 加权投票法 (weighted voting)

$$H(\mathbf{x}) = c_{\arg \max_j \sum_{i=1}^T w_i h_i^j(\mathbf{x})}$$

结合策略 – 学习法

- Stacking是学习法的典型代表

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
初级学习算法 $\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_T$;
次级学习算法 \mathcal{L} .

过程:

```
1: for  $t = 1, 2, \dots, T$  do
2:    $h_t = \mathcal{L}_t(D)$ ;
3: end for
4:  $D' = \emptyset$ ;
5: for  $i = 1, 2, \dots, m$  do
6:   for  $t = 1, 2, \dots, T$  do
7:      $z_{it} = h_t(\mathbf{x}_i)$ ;
8:   end for
9:    $D' = D' \cup ((z_{i1}, z_{i2}, \dots, z_{iT}), y_i)$ ;
10: end for
11:  $h' = \mathcal{L}(D')$ ;
输出:  $H(\mathbf{x}) = h'(h_1(\mathbf{x}), h_2(\mathbf{x}), \dots, h_T(\mathbf{x}))$ 
```

集成学习

- 个体与集成
- Boosting
 - Adaboost
- Bagging与随机森林
- 结合策略
 - 平均法
 - 投票法
 - 学习法
- 多样性
 - 误差-分歧分解
 - 多样性度量
 - 多样性扰动

多样性 - 误差-分歧分解

- 定义学习器 h_i 的**分歧**(ambiguity) :

$$A(h_i \mid \mathbf{x}) = (h_i(\mathbf{x}) - H(\mathbf{x}))^2$$

□ 集成的分歧 :

$$\begin{aligned}\bar{A}(h \mid \mathbf{x}) &= \sum_{i=1}^T w_i A(h_i \mid \mathbf{x}) \\ &= \sum_{i=1}^T w_i (h_i(\mathbf{x}) - H(\mathbf{x}))^2\end{aligned}$$

多样性 - 误差-分歧分解

- 分歧项代表了个体学习器在样本 \mathbf{x} 上的不一致性，即在一定程度上反映了个体学习器的多样性，个体学习器 h_i 和集成 H 的平方误差分别为

$$E(h_i | \mathbf{x}) = (f(\mathbf{x}) - h_i(\mathbf{x}))^2$$

$$E(H | \mathbf{x}) = (f(\mathbf{x}) - H(\mathbf{x}))^2$$

多样性 - 误差-分歧分解

- 令 $\overline{E}(h \mid \mathbf{x}) = \sum_{i=1}^T w_i \cdot E(h_i \mid \mathbf{x})$ 表示个体学习器误差的加权均值, 有

$$\begin{aligned}\overline{A}(h \mid \mathbf{x}) &= \sum_{i=1}^T w_i E(h_i \mid \mathbf{x}) - E(H \mid \mathbf{x}) \\ &= \overline{E}(h \mid \mathbf{x}) - E(H \mid \mathbf{x}) .\end{aligned}$$

- 上式对所有样本 \mathbf{x} 均成立, 令 $p(\mathbf{x})$ 表示样本的概率密度, 则在全样本上有

$$\sum_{i=1}^T w_i \int A(h_i \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x} = \sum_{i=1}^T w_i \int E(h_i \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x} - \int E(H \mid \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

多样性 - 误差-分歧分解

- 个体学习器 h_i 在全样本上的泛化误差和分歧项分别为：

$$E_i = \int E(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

$$A_i = \int A(h_i | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 集成的泛化误差为：
$$E = \int E(H | \mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

- 令 $\bar{E} = \sum_{i=1}^T w_i E_i$ 表示个体学习器泛化误差的加权均值，
 $\bar{A} = \sum_{i=1}^T w_i A_i$ 表示个体学习器的加权分歧值，有

$$E = \bar{E} - \bar{A}$$

多样性 - 误差-分歧分解

- 这个漂亮的式子显示: **个体学习器精确性越高、多样性越大, 则集成效果越好。称为误差-分歧分解**
- 为什么不能直接把 $\bar{E} - \bar{A}$ 作为优化目标来求解?
 - 现实任务中很难直接对 $\bar{E} - \bar{A}$ 进行优化,
 - 它们定义在整个样本空间上
 - \bar{A} 不是一个可直接操作的多样性度量
 - 上面的推导过程只适用于回归学习, 难以直接推广到分类学习任务上去

多样性 - 多样性度量

- 多样性度量(diversity measure)用于度量集成中个体学习器的多样性
- 对于二分类问题，分类器 h_i 与 h_j 的预测结果联立表(contingency table)为

	$h_i = +1$	$h_i = -1$
$h_j = +1$	a	c
$h_j = -1$	b	d

$$a + b + c + d = m$$

多样性 - 多样性度量

□ 常见的多样性度量

- 不合度量(Disagreement Measure)

$$dis_{ij} = \frac{b + c}{m}$$

- 相关系数(Correlation Coefficient)

$$\rho_{ij} = \frac{ad - bc}{\sqrt{(a + b)(a + c)(c + d)(b + d)}}$$

多样性 - 多样性度量

□ 常见的多样性度量

- Q-统计量(Q-Statistic)


$$Q_{ij} = \frac{ad - bc}{ad + bc} \quad |Q_{ij}| \leq |\rho_{ij}|$$

- k -统计量(Kappa-Statistic)


$$\kappa = \frac{p_1 - p_2}{1 - p_2} \quad \begin{aligned} p_1 &= \frac{a + d}{m}, \\ p_2 &= \frac{(a + b)(a + c) + (c + d)(b + d)}{m^2} \end{aligned}$$

多样性 - 多样性度量

□ k - 误差图



(a) AdaBoost 集成



(b) Bagging 集成

课堂测验

- k - 误差图，如点云出现在右下角，则代表（ ）
- A 个体学习器精度高，个体学习器多样性大
- B 个体学习器精度高，个体学习器多样性小
- C 个体学习器精度低，个体学习器多样性大
- D 个体学习器精度低，个体学习器多样性小

多样性 – 多样性增强

□ 常见的增强个体学习器的多样性的方法

- ✓ 数据样本扰动
- ✓ 输入属性扰动
- ✓ 输出表示扰动
- ✓ 算法参数扰动

多样性 – 多样性增强 – 数据样本扰动

□ 数据样本扰动通常是基于采样法

- Bagging中的自助采样法
- Adaboost中的序列采样

数据样本扰动对“不稳定基学习器”很有效

□ 对数据样本的扰动敏感的基学习器(不稳定基学习器)

- 决策树，神经网络等

□ 对数据样本的扰动不敏感的基学习器(稳定基学习器)

- 线性学习器，支持向量机，朴素贝叶斯，k近邻等

多样性 – 多样性增强 – 输入属性扰动

□ 随机子空间算法(random subspace)

输入: 训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$;
基学习算法 \mathcal{L} ;
基学习器数 T ;
子空间属性数 d' .

过程:

```
1: for  $t = 1, 2, \dots, T$  do  
2:    $\mathcal{F}_t = \text{RS}(D, d')$   
3:    $D_t = \text{Map}_{\mathcal{F}_t}(D)$   
4:    $h_t = \mathcal{L}(D_t)$   
5: end for
```

输出: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\text{Map}_{\mathcal{F}_t}(\mathbf{x})) = y)$

多样性 – 多样性增强 – 输出表示扰动

□ 翻转法(Flipping Output)

□ 输出调剂法(Output Smearing)

□ ECOC法

多样性 – 多样性增强 – 算法参数扰动

□ 负相关法

□ 不同的多样性增强机制同时使用

阅读材料

- 集成学习方面的主要推荐读物是[Zhou,2012]，本章提及的所有内容在该书中都有更深入的详细介绍。[Kuncheva,2004;Rockach,2010b]可供参考，[Schapire and Freund,2012]则是专门关于Boosting的著作，集成学习方面有一些专门性的会议MCS(International Workshop on Multiple Classifier System).
- Boosting源于[Schapire,1990]对[Kearns and Valiant,1989]提出的“弱分类器是否等价于强学习”这个重要理论问题的构造性证明。最初的Boosting算法仅有理论意义，经数年努力后[Freund and Schapire,1997]提出Adaboost，并因此或得理论计算机科学方面的重要奖项—哥德尔奖。关于Boosting和Bagging已有的很多理论研究成果课参阅[Zhou,2012]第2-3章。

-
- **作业：网上下载或自己编程实现随机森林算法，在西瓜数据集3.0a（p.89表4.5）上测试算法性能（如参数敏感性、训练精度、收敛速度、运行时间等），并分析。提交实验报告。**

谢 谢！